

武汉大学国家网络安全学院

课程实验报告

大数据分析

专业名称：信安 & 网安

课程名称：大数据分析

指导教师：汪 润

小组成员：张鉴殊 2021302181216

傅彦凯 2021302191289

彭子恒 2021302091053

二〇二三 年 十二 月

目录

一、实验完成情况与分工	2
二、实验背景	2
三、实验环境	3
四、实验内容与原理	3
4.1 实验目的	3
4.2 实验步骤	3
4.3 实验原理	3
4.4 实验任务	4
五、实验步骤与分析	5
5.1 数据集获取	5
5.2 数据预处理	7
5.3 数据存储	8
5.4 数据分析及其结果可视化	9
5.4.1 最近一年 CS 不同子领域论文数量分析	9
5.4.2 对子领域进行逐年分析	10
5.4.3 对于热门的 cs 领域进行逐月的数量分析	12
5.4.4 分析 CS 类别和其他类别的交叉数量	12
5.4.5 CS 领域和其他 CS 领域之间的关联	13
5.4.6 最后一次提交的版本和第一次提交版本的时间间隔	14
5.5 算法设计——针对更细粒度的划分	15
5.5.1 问题的背景	15
5.5.2 Kmeans 聚类	16
5.5.3 特征提取	16
5.5.4 结果分析	17
六、实验感想与致谢	19
七、附录：配置 hadoop 环境（ubuntu20.04）	21



基于 Spark 的 CS 学术发展趋势分析

一、 实验完成情况与分工

在本次实验中，我们利用 Spark 大数据分析工具，针对 arXiv 中计算机学科相关的论文，对六个任务做出了细致的分析，并可视化呈现了实验的结果。此外我们在基本的分析任务上进行扩展，针对 arXiv 中 CS 论文的子领域划分不够细致的问题，设计了一种无监督聚类的算法，将 CS 领域的论文进行了更细粒度的划分。

我们小组的分工情况如下：

张鉴殊：任务三、任务四、任务五、任务六及数据可视化

傅彦凯：数据的爬取、数据的预处理、任务一、任务二及数据可视化

彭子恒：实验背景分析、扩展任务算法的设计与实现，数据的可视化

二、 实验背景

在信息技术迅速发展的当今社会，计算机科学（CS）领域的学术研究不断涌现出大量的高质量论文。这些论文记录了学术界在各个细分领域的最新研究成果和创新。为了更深入地了解 CS 领域的学术前沿趋势，我们小组打算利用大数据分析技术，从海量的论文数据中挖掘有价值的信息。

arXiv，作为一个开放获取的学术预印本存储库，为多个科学领域的科学研究人员提供了一个分享和传播研究成果的平台，其中也包含了大量 CS 领域的高质量论文。它允许研究人员在论文正式发表之前分享他们的研究成果。这种预印本的形式使得同行和其他研究人员能够更早地了解最新的研究动态，促进了科学知识的及时传播。因此我们小组决定以 arXiv 上的 CS 论文作为我们分析的主要对象。

本次实验旨在利用 Hadoop 和 Spark 等大数据处理框架，通过对 CS 学术文献的综合分析，深入挖掘计算机科学领域的发展趋势。通过构建一个包含多个子领域的广泛而细致的数据集，全面地了解近年来计算机科学领域的研究动态。同时，通过使用大数据处理工具，高效地处理庞大的文献数据集，挖掘隐藏在其中的规律和趋势。

为了更好地支持学术研究和未来的科学发展，本实验还着重关注了计算机科学领域与其他学科领域的交叉关系。通过分析不同学科之间的合作和影响，研究者们能够更好地把握科学的整体格局，促进跨学科合作和知识交流。

另外，基于 arXiv 论文数据库中领域划分不够细致的问题，本实验通过对特定领域进行更详细的分类，让研究者能够更准确地了解论文的具体研究方向，从而更有针对性地获取相关信息。以计算机科学领域为例，CS 领域包含众多子领域，如计算机视觉（CV）、数据库（DB）、机器学习（ML）等，而这些子领域内部又涉及到更具体的主题和任务。因此，将 CS 领域的论文进一步划分为更具体的细分方向，对于研究者深入了解计算机科学的前沿趋势和专业领域非常重要。



三、 实验环境

- 操作系统: Linux: Ubuntu 20.04 (VMware Workstation Pro 16.2.4)
- IDE: Visual Studio Code
- 编程语言: Python 3.9
- 工具: Hadoop 3.2.4、Spark 3.2.4

四、 实验内容与原理

4.1 实验目的

1. 熟悉 Hadoop 等分布式计算平台
2. 构建 arXiv 上 CS 类论文的数据库
3. 使用 Hadoop 和 Spark 工具对 arXiv 数据集进行统计分析
4. 设计算法，使用 sparkml 库进行更深层次数据分析

4.2 实验步骤

step 1: 利用 python 爬取 arXiv 官网中 CS 类的论文数据

step 2: 数据预处理

step 3: 使用 HDFS 文件系统存储数据

step 4: 利用 Spark 对数据进行分析

step 5: 可视化呈现结果

4.3 实验原理

1. Hadoop

- 介绍: Hadoop 是一个开源的分布式计算框架，用于处理大规模数据集的分布式存储和处理。它基于 Google 的 MapReduce 论文提出的编程模型，采用分布式文件系统 (HDFS) 来存储大规模数据，并使用 MapReduce 编程模型来处理这些数据。
- 核心组件:



- **Hadoop 分布式文件系统 (HDFS):** HDFS 是 Hadoop 的分布式文件系统，用于存储大规模数据集。它将数据分散存储在集群的多个节点上，提供高容错性和可靠性。
- **MapReduce:** MapReduce 是 Hadoop 的编程模型，用于处理大规模数据集的分布式计算。它包括两个主要阶段：Map 阶段（数据切分和映射）和 Reduce 阶段（合并和归约），允许用户通过编写简单的 Map 和 Reduce 任务来处理数据。
- **Hadoop YARN:** YARN (Yet Another Resource Negotiator) 是 Hadoop 的资源管理器，负责集群上的资源分配和作业调度。它允许多个应用程序共享集群资源，提高资源的利用率。

2. spark

- 介绍：Apache Spark 是一个基于内存的分布式计算框架，用于大规模数据处理和分析。与 Hadoop 相比，Spark 更加灵活，支持更复杂的计算流程，并提供更高效的数据处理能力。
- 核心组件：
 - **Spark Core:** Spark 核心模块提供了任务调度、内存管理和错误恢复等基本功能。它定义了弹性分布式数据集（RDD）作为基本数据结构。
 - **Spark SQL:** 用于结构化数据处理的 Spark 模块。它允许使用 SQL 查询处理数据，并与 Spark 程序集成。
 - **Spark Streaming:** 用于实时数据处理的 Spark 模块。它支持流式数据的高级抽象，使得开发者能够使用批处理和流处理相同的 API。
 - **MLlib:** Spark 的机器学习库，提供了分布式机器学习算法和工具。

4.4 实验任务

通过自己构建的 CS 论文数据集来进行数据分析，为了更好的研究 CS 学科前沿的发展趋势，我们对不同子领域的论文数量、发展变化趋势、类间关系作了一定的分析。制定了下列六个基本的任务：

- 最近一年 CS 不同子领域论文数量分析
- 分析子领域论文数量在 2007 年-2023 年间的变化趋势
- 对热门的 CS 子领域进行逐月的数量统计
- 分析 CS 类别与其他类别的交叉关联性
- 分析 CS 各子领域之间的相互关联
- 分析最后一次提交版本和第一次提交版本的时间间隔



最后我们针对以上分析的结果，发现 arXiv 对于 CS 类别论文的标签划分存在定界模糊、不够细致的问题，对研究人员查找相关领域的论文造成了一定的阻碍。因此我们基于 Kmeans 无监督聚类的方法，对子领域的论文进行更细粒度的划分，方便研究者更准确地获取相关信息。

五、实验步骤与分析

5.1 数据集获取

由于我们并没有找到现有的公开数据集，因此需要对数据进行爬取。我们可以访问 arXiv 官网 <https://arxiv.org/>。arXiv 是一个开放获取的学术预印本存储库，包含了许多不同学科领域的论文，包括物理学、数学、计算机科学、量子物理学、生物学等等。本次实验我们重点分析计算机 (CS) 学科的前沿发展趋势，因此现在官网上对计算机学科的论文进行初步筛选。

为了对计算机学科的前沿发展趋势做出细致的分析，我们选定时间从 2007 年 1 月 1 日至 2023 年 12 月 1 日的 cs 类所有论文。同时为了减少不必要的开销，隐藏文章的摘要部分。

The screenshot shows the arXiv search interface with the following filters applied:

- Subject:** Computer Science (cs) is selected.
- Date:** Date range is set from 2007-01-01 to 2023-12-01.
- Abstracts:** Show abstracts is selected.

图 1: 筛选 CS 论文

数据爬取的具体流程不外乎包括四个部分：发送 HTTP 请求、解析 HTML 内容、提取信息、保存数据。我们得到的网页信息和 HTML 信息如图 2 所示。



Query: order: announced_date:first; size: 200; hide_abstracts: True; date_range: from 2023-01-01 to 2023-12-01; classifier: Computer Science (ccs) include, cross_list: True

Simple Search

200 results per page. Sort results by: announcement date (newest first)

1. arXiv:2312.10042 [pdf] [tex] [code] [arXiv]

A Generic Stochastic Hybrid Car-following Model Based on Approximate Bayesian Computation

Authors: Jieun Jiang, Yang Zhou, Xin Wang, Sopyoung Ahn

Submitted 26 November, 2023; originally announced December 2023

Comments: 25 pages, 6 figures

2. arXiv:2312.10041 [pdf] [tex] [code] [arXiv]

Digital Twin Technology Enabled Proactive Safety Application for Vulnerable Road Users: A Real-World Case Study

Authors: Md. Nazrul Hasan Shabik, Sagar Dasgupta, Mizanur Rahman, Steven Jones

Submitted 24 November, 2023; originally announced December 2023

Comments: 19 pages, 8 figures, submitted to the Transportation Research Board 2024 TBM Annual Meeting

3. arXiv:2312.10040 [pdf] [other] [arXiv]

Robust Errant Beam Prognostics with Conditional Modeling for Particle Accelerators

Authors: Krishnaraj Bagul, Malachi Schram, Willem Blokland, Yasir Alazizi, Pradeep Ramuhalli, Alexander Zhukov, Charles Peters, Ricardo Villalba

Submitted 26 November, 2023; originally announced December 2023

Comments: Under review at Machine Learning: Science and Technology Journal

4. arXiv:2312.10039 [pdf] [tex]

Data Silos & Roadblock for AIOps

Authors: Sushil Kumar

Submitted 21 November, 2023; originally announced December 2023

5. arXiv:2312.09449 [pdf] [other] [arXiv] [arXiv]

Clinical Text Deduplication Practices for Efficient Pretraining and Improved Clinical Tasks

Authors: Nottia Landi, Eugenia Alleva, Alissa A. Valentine, Lauren A. Lepow, Alexander W. Chamey

Submitted 29 September, 2023; originally announced December 2023

6. arXiv:2312.09448 [pdf] [other] [arXiv] [arXiv]

Safe Reinforcement Learning in a Simulated Robotic Arm

Authors: Lukáš Kováč, Igor Faršík

Submitted 28 November, 2023; originally announced December 2023

Comments: 10 pages, 6 figures

7. arXiv:2312.09407 [pdf] [other] [arXiv] [arXiv]

Performance Analysis of Fixed Broadband Wireless Access in mmWave Band in 5G

Authors: Soumya Banerjee, Seeta Patel Gochhayat, Sachin Shetty

Submitted 28 November, 2023; originally announced December 2023

图 2: HTML 信息

经过分析和筛选，最终选择以下信息进行爬取：

- arXiv ID: 每篇 arXiv 上的论文都有一个唯一的标识。
- 标题: 论文地题目, 用于后续更细粒度的划分。
- 标签: 用于描述论文主题、领域或关键词, 讲论文分类到适当主题下。
- 作者: 列举了负责进行研究并贡献到论文的个人或团队。
- 提交日期: 论文在 arXiv 上首次提交的时间。
- 最初公布日期: 论文在 arXiv 上首次公开发布的日期。这可能与提交日期相同, 但也可能在之后进行更新或修订。

我们利用 python 的 HTML 解析库 BeautifulSoup 对 HTML 网页进行解析, 然后定位和提取页面上的具体元素, 过滤掉不关心的数据。由于数据量庞大, 数据分布在多个页面上, 因此需要考虑分页, 对每一页进行爬取, 最后再进行整合, 这里我们利用循环遍历页面来实现相同的目的。

最终一共得到 529077 条论文数据, 这个数据量已经相当庞大, 且具有一定的多样性, 能更好地支持整体的泛化, 最终的结论具有更加广泛的适用性。



arXiv ID, 标题, 标签, 作者, 提交日期, 最初公布日期
arXiv:2212.00280, GRIT: A Generative Region-to-text Transformer for Object Understanding, ['cs.CV'], ['Jialian Wu', 'Jianfeng Lu'], 2022-12-01, 2022-12-01
arXiv:2212.00281, Localization vs. Semantics: How Can Language Benefit Visual Representation Learning?, ['cs.CV', 'cs.CL'], 2022-12-01, 2022-12-01
arXiv:2211.16696, Automated anomaly-aware 3D segmentation of bones and cartilages in knee MR images from the Osteoarthritis Biobank, ['cs.CV'], [Liangchen Liu, Jiaxin Wang, Mingming Li, Yuxuan Chen, Zhenyu Guo, Xiangyu Zhou, Junjie Bai], 2022-11-28, 2022-11-28
arXiv:2211.02883, Unified Multi-View Orthonormal Non-Negative Graph Based Clustering Framework, ['cs.CV'], [Liangchen Liu, Jiaxin Wang, Mingming Li, Yuxuan Chen, Zhenyu Guo, Xiangyu Zhou, Junjie Bai], 2022-11-28, 2022-11-28
arXiv:2211.13578, Multiagent MST Cover: Pleasing All Optimally via A Simple Voting Rule, ['cs.GT'], [Bing Li, Xiaowei Wu], 2022-11-28, 2022-11-28
arXiv:2212.00285, Hybrid Life: Integrating Biological, Artificial, and Cognitive Systems, ['cs.AI', 'eess.SY', 'q-bio.NC'], 2022-12-01, 2022-12-01
arXiv:2110.08673, Scaling Blockchains: Can Committee-Based Consensus Help?, ['cs.CR', 'cs.GT', 'cs.IT', 'econ.GN', 'q-fin.CP'], 2021-10-19, 2021-10-19
arXiv:2212.00288, Locally Adaptive Hierarchical Cluster Termination With Application To Individual Tree Delineation, ['stat.CO'], [Yiwei Wang, Mingming Li, Junjie Bai, Mingming Li, Junjie Bai], 2022-12-01, 2022-12-01
arXiv:2212.00291, The Effect of Data Dimensionality on Neural Network Prunability, ['cs.LG'], [Zachary Ankner, Alex Ren, Bo Tang, Tianqi Chen], 2022-12-01, 2022-12-01
arXiv:2212.00292, Economics of NFTs: The Value of Creator Royalties, ['econ.GN', 'cs.CR', 'cs.MA', 'q-fin.TR'], [Brett Bernstein, Michael F. Tiernan, Michael F. Tiernan], 2022-12-01, 2022-12-01
arXiv:2211.12006, Differentiable Fuzzy \mathcal{ALC} : A Neural-Symbolic Representation Language for Symbol Grounding, ['cs.LG', 'math.PR', 'math.RT'], [Yuansi Chen, Ronen Elkin, Shlomo Shamir], 2022-11-28, 2022-11-28
arXiv:2212.00297, Hit-and-run mixing via localization schemes, ['math.PR', 'cs.CC', 'stat.CO'], [Yuansi Chen, Ronen Elkin, Shlomo Shamir], 2022-12-01, 2022-12-01
arXiv:2212.00298, A Commonsense-Infused Language-Agnostic Learning Framework for Enhancing Prediction of Political Polarization, ['cs.LG'], [Rishabh Iyer, Suresh Venkatasubramanian, Suresh Venkatasubramanian], 2022-12-01, 2022-12-01
arXiv:2202.02902, Redactor: A Data-centric and Individualized Defense Against Inference Attacks, ['cs.LG', 'cs.AI', 'cs.CC'], 2022-02-14, 2022-02-14
arXiv:2208.13753, Frido: Feature Pyramid Diffusion for Complex Scene Image Synthesis, ['cs.CV', 'cs.AI', 'cs.LG'], [Wan-Cyuan Fan, Cheng-Fu Yu, Mingming Li, Junjie Bai], 2022-08-22, 2022-08-22
arXiv:2211.14544, Target-Free Text-guided Image Manipulation, ['cs.CV', 'cs.AI', 'cs.LG'], [Wan-Cyuan Fan, Cheng-Fu Yu, Mingming Li, Junjie Bai], 2022-11-28, 2022-11-28
arXiv:2212.00305, Multilingual Communication System with Deaf Individuals Utilizing Natural and Visual Languages, ['cs.CV'], [Shlok Kumar Mishra, Jurek Leonhardt, Koustav Rudra], 2022-12-01, 2022-12-01
arXiv:2103.12201, Improved Detection of Face Presentation Attacks Using Image Decomposition, ['cs.CV'], [Shlok Kumar Mishra, Jurek Leonhardt, Koustav Rudra], 2021-03-26, 2021-03-26
arXiv:2106.12460, Extractive Explanations for Interpretability Ranking, ['cs.IR'], [Jurek Leonhardt, Koustav Rudra], 2021-06-26, 2021-06-26
arXiv:2211.11751, Denoising Multi-Similarity Formulation Col 2:标题-paced Curriculum-Driven Approach for Robust Metric Learning, ['cs.LG', 'math.OC'], [Chengming Cai, Mingming Li, Junjie Bai], 2022-11-22, 2022-11-22
arXiv:2212.00211, Generalizing and Temporizing Jacobians and Hessian Regularization, ['cs.LG', 'math.OC'], [Chengming Cai, Mingming Li, Junjie Bai], 2022-12-01, 2022-12-01

图 3: 数据集

5.2 数据预处理

在爬取得到的论文数据中，我们发现了一些特殊字符，这可能会对后续的分析和处理造成影响。因此，我们先对数据进行预处理，主要包括去除特殊的字符和标点符号。

结合 pandas 工具和下面的函数，读取原始数据后对其进行处理。经过处理后数据格式都十分统一，磨刀不误砍柴工，经过处理之后，接下来的数据分析就容易多了。

```
1 def remove_symbols(s):
2     return ''.join(e for e in s if e not in ('\\', '\\n', '[', ']', ';'))
```

同时为了便于对后续 CS 小类进行分析，我们分别筛选了下列六个具有代表性且重合程度较低的子类进行深入的分析：

- **cs.CV**: 计算机视觉与模式识别，关注计算机系统如何从图像或视频中提取信息，以及如何对这些信息进行理解和分析。
- **cs.CL**: 计算与语言，涉及计算机科学与自然语言处理的交叉领域。
- **cs.SE**: 软件工程，研究如何有效地设计、开发和维护软件系统。
- **cs.NI**: 网络和互联网体系结构，关注计算机网络和互联网技术的研究。
- **cs.DB**: 数据库，涉及设计、实现和管理数据库系统的研究。
- **cs.DC**: 分布式、并行和集群计算，研究如何有效地利用多个计算资源进行并行处理和集群计算

这些子领域都代表了计算机科学领域中的不同方面和研究方向，它们涵盖了计算机科学领域内广泛多样的问题，这种多样性反映了计算机科学作为一个综合性学科的复杂性和丰富性。



5.3 数据存储

HDFS 是 Apache Hadoop 生态系统的一部分，用于存储和管理大规模数据集。它是一个分布式文件系统，设计用于在集群中存储和处理大量数据。HDFS 将数据划分成块，并在集群中的多个节点上进行分布式存储。

我们讲爬取的数据存储在 HDFS 文件系统中，具体的操作步骤如下：

- **安装和配置 Hadoop**: 在官方网站下载 Hadoop，并根据需求进行配置，包括配置环境变量。
- **启动 Hadoop 集群**: 使用 Hadoop 启动脚本启动 HDFS 集群。这包括启动 NameNode (主节点) 和 DataNode (数据节点)，通过在终端中输入下列命令

```
1 ./hadoop/sbin/start-dfs.sh
```

- **创建 HDFS 目录**: 在 HDFS 文件系统中创建一个目录，用于存放预处理后的数据，可以输入下列指令完成

```
1 hdfs dfs -mkdir /user/hadoop/input
```

- **上传数据到 HDFS**: 利用下列指令，将 dataset 文件夹中的所有数据上传到 HDFS 文件系统的指定目录下

```
1 hdfs dfs -put dataset/* input/
```

- **检查数据存储情况**: 可使用以下命令检查数据是否成功上传到 HDFS 中

```
1 hdfs dfs -ls input/
```

根据下图结果可以看到，10 份 csv 数据已经全部成功上传至 HDFS 文件系统中。

```
(base) hadoop@ubuntu:~/bigdata$ hdfs dfs -ls input/
Found 10 items
-rw-r--r-- 1 hadoop supergroup 116509228 2023-12-19 19:24 input/07-23arxiv_data.csv
-rw-r--r-- 1 hadoop supergroup 24590985 2023-12-19 19:24 input/arxiv_data.csv
-rw-r--r-- 1 hadoop supergroup 10728811 2023-12-19 19:24 input/cs_CL.csv
-rw-r--r-- 1 hadoop supergroup 22865991 2023-12-19 19:24 input/cs_CV.csv
-rw-r--r-- 1 hadoop supergroup 1520712 2023-12-19 19:24 input/cs_DB.csv
-rw-r--r-- 1 hadoop supergroup 4018657 2023-12-19 19:24 input/cs_DC.csv
-rw-r--r-- 1 hadoop supergroup 4189366 2023-12-19 19:24 input/cs_N1.csv
-rw-r--r-- 1 hadoop supergroup 2949640 2023-12-19 19:24 input/cs_SE.csv
-rw-r--r-- 1 hadoop supergroup 106872598 2023-12-19 19:24 input/new_07-23arxiv_data.csv
-rw-r--r-- 1 hadoop supergroup 22537481 2023-12-19 19:24 input/new_arxiv_data.csv
```

图 4: HDFS 文件系统存储数据

5.4 数据分析及其结果可视化

5.4.1 最近一年 CS 不同子领域论文数量分析

为了了解计算机科学领域最近的研究趋势，我们首先分析最近一年来，计算机科学中各个子领域论文数量。我们选择时间段从 2022 年 12 月 1 日到 2023 年 12 月 1 日的论文进行统计。考虑到一篇论文可能存在多个标签，那么该篇论文属于多个子领域。

结果如图 5 所示，论文发表数量最多的五个子领域是 LG (机器学习)、CV (计算机视觉)、AI (人工智能)、CL (计算语言)、RO (机器人技术)，我们发现这五个领域之间具有一定的共性，存在技术交叉，人工智能领域涵盖了机器学习、计算语言、计算机视觉，而机器人技术与机器学习、人工智能也具有较大的关联性，这说明了人工智能是目前计算机最火热的领域，与其高度相关的计算机视觉、自然语言处理、自动化技术等发展速度很快，这也说明了计算机科学领域正朝着更加智能、自动化、数据驱动的方向发展。

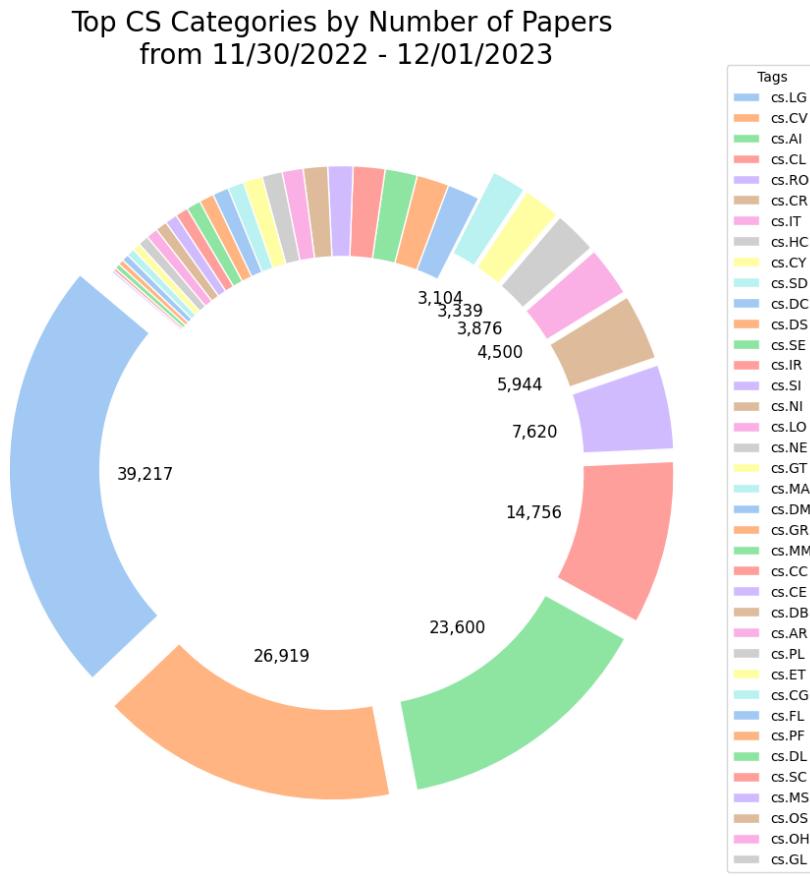


图 5: 近一年 CS 不同子领域论文数量

在上面的统计结果上，我们绘制词云图来可视化呈现不同领域的论文数量占比，在视觉上更加富有冲击力。不同的颜色代表了不同的子领域，而不同的字体大小展示出了不同领域论文的数量值。

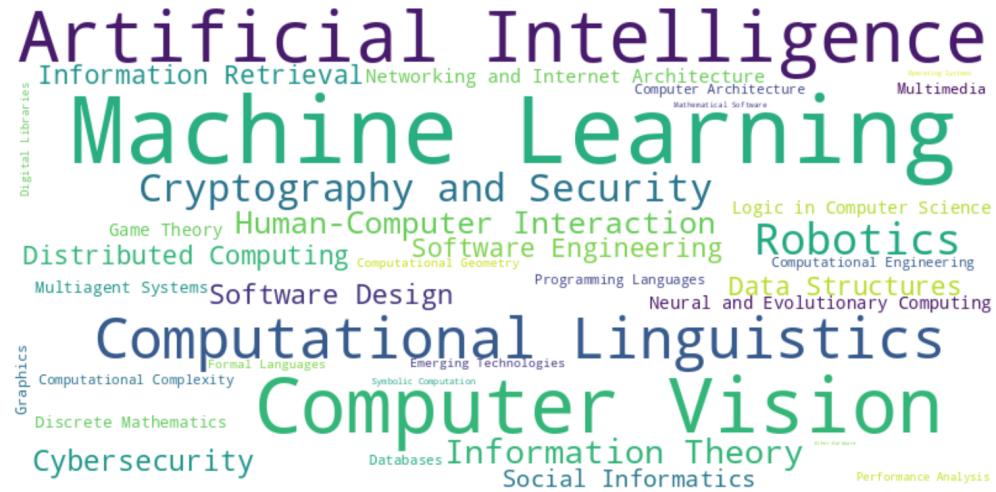


图 6: 词云图

5.4.2 对子领域进行逐年分析

根据上一问的分析，计算机不同子领域的论文数量有很大的差别，这说明不同领域的热门程度不同。在这一问中，我们对各小类论文数量进行逐年统计，来分析不同子领域的发展趋势。

我们主要选择了 6 个计算机子领域，包括 CV（计算机视觉）、CL（计算语言）、SE（软件工程）、NI（网络结构）、DB（数据库）、DC（分布式计算）。它们是计算机学科中比较具有代表性的领域，同时它们之间的重合度较低，涵盖范围较广。

使用 Pyspark 工具进行分析，结果如图 7 所示，这里需要注意，柱状图的纵坐标刻度不同。根据可视化结果可以很明显观察到，CV、CL 领域在论文在数量上相比其他四个子领域具有明显的优势，并且他们的发展速度非常快，CV 类论文在 2007 年数量仅为 62，但是在 2023 年截至 12 月 1 日，论文数量已经超过 25000 篇，发展速度远远超过了其他各个领域。

而相比之下，NI、DB、DC 等传统的计算机领域发展速度比较缓慢，尤其是 NI 领域，近四年的论文数量没有发生明显的增长。这也说明了随着人工智能和硬件技术的发展，AI 相关领域在近年来得到了非常快的发展。

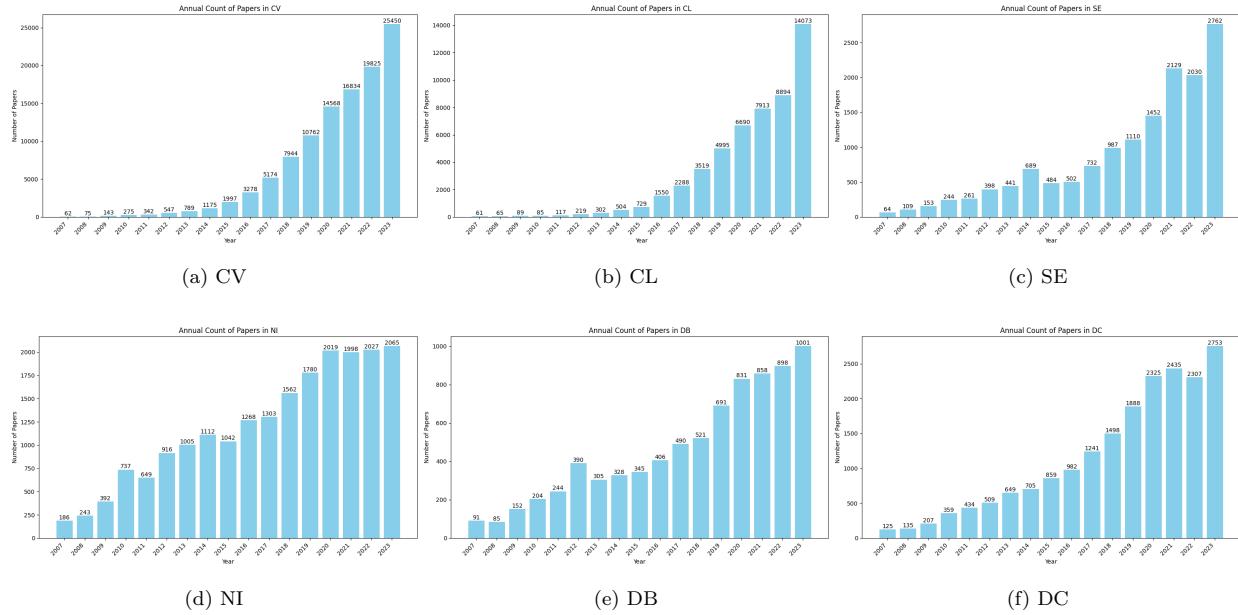


图 7: 六类子领域论文数量变化趋势

我们将 CS 类六个子领域的论文发表数量绘制在一张图上，如图 8 所示，对比之下，很容易能看出不同领域的发展变化趋势。CV、CL 等领域的发展趋势远远领先于其他领域。

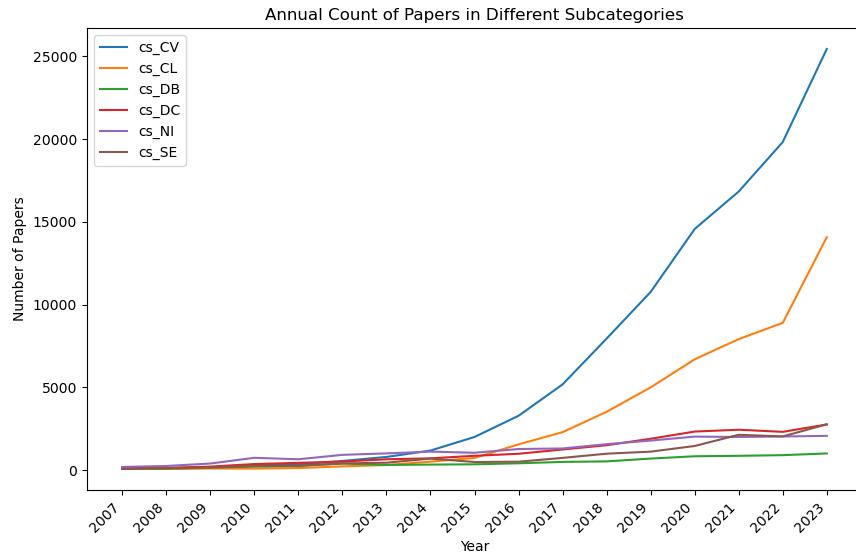


图 8: CS 各子领域论文数量变化曲线图

5.4.3 对于热门的 cs 领域进行逐月的数量分析

在前面的“最近一年 CS 不同子领域论文数量分析”任务中，我们分析得到从 2022 年 12 月 1 日到 2023 年 12 月 1 日中最热门的五个领域：LG（机器学习）、CV（计算机视觉）、AI（人工智能）、CL（计算语言）、RO（机器人技术）。

在本任务中，我们逐月分析 CV 领域论文数量变化趋势，探究对于 CV 领域发论文较多的时期。

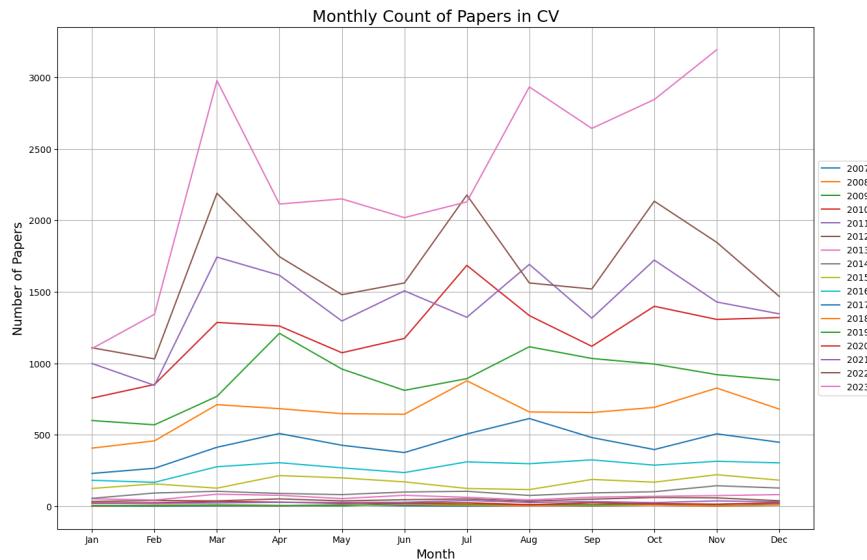


图 9: CV 领域论文数量逐月分析

对图 9 分析发现，CV 领域论文发布主要有三个高峰期：3 月、7-8 月、10 月。我们猜测 CV 领域论文发布高峰期与 CV 领域顶级会议举办时间有一定联系，3 月之所以有这么多 CV 领域的论文发表，可能是因为 CVPR 在每年六月份举办。

5.4.4 分析 CS 类别和其他类别的交叉数量

图 10 覆盖了从 2022 年 12 月 1 日到 2023 年 12 月 1 日的不同的学术分类之间的关系，如计算机科学 (cs)、工程和环境科学 (eess)、统计学 (stat)、数学 (math) 以及物理学 (physics)。节点间的连线代表了不同学科之间的关系，节点的大小代表该领域的活跃度或者在网络中的重要性，而节点之间的连线则代表关系的强度以及频繁程度。在这 cs.AI 节点非常突出，表明人工智能是一个与众多其他学科有广泛联系的领域。同时可以看出 cs 与各个领域都有广泛的联系，特别是与统计学 (stat.ML 代表机器学习) 和各个工程科学 (eess) 领域的紧密联系。

总的来说，这张图揭示了现代科研的一个特点：不同学科之间的界限越来越模糊，cs 跨学科的合作变得越来越普遍。每个学科领域都不是孤立的，而是通过各种形式与其他领域相连结，共同推动科学的进步。

Catagory Relationship Network
from 11/30/2022 - 12/01/2023

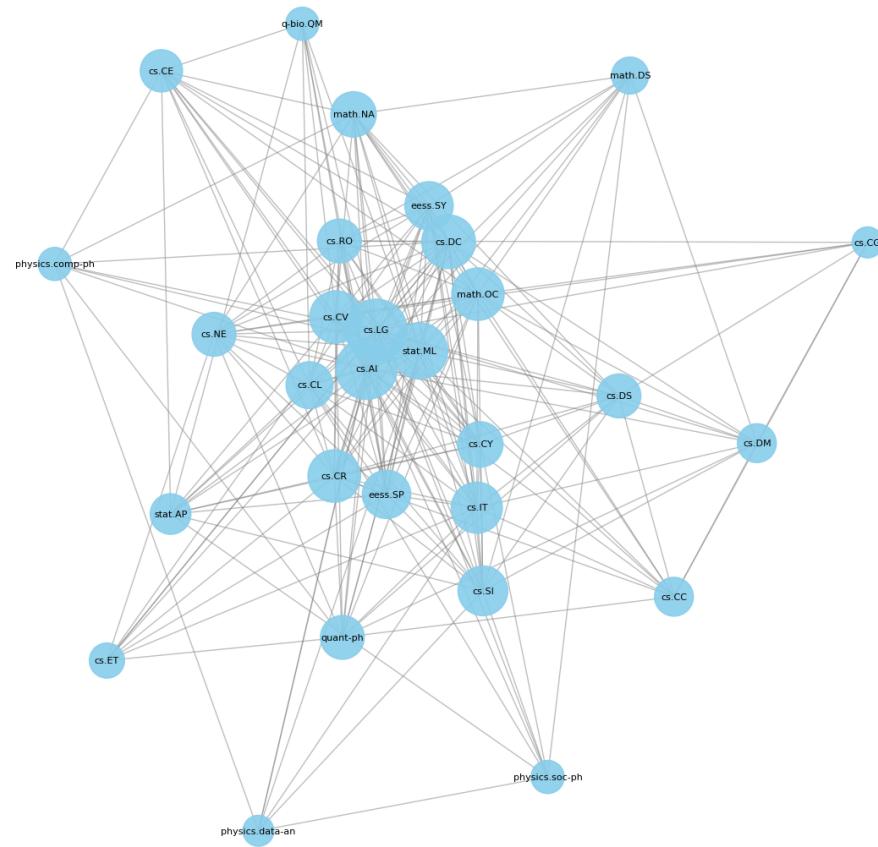


图 10: 不同学科领域之间关系的网络关系图

5.4.5 CS 领域和其他 CS 领域之间的关联

一篇论文在 arXiv 数据集中会被打上一个或者多个领域的标签。如果一篇论文被同时打了 cs.AI 和 cs.CV 这两个标签，那么我们可以认为这篇论文是关于 AI 领域和 CV 领域的交叉方向。如果在 arXiv 论文数据集中，cs.AI 和 cs.CV 同时出现在大量论文中（相对整个数据集而言），可以说明这两个领域存在比较强的关联性。

以图 11为例，图 11说明 CV 与 LG 有极强的关联性，和 AI、eess.IV 也有不错的关联，和 RO、CL 有一定的关联性。总的说来，CV、AI、CL 这三个领域和 LG 领域都有着极强的联系，说明现在机器学习方法已经成为计算机视觉、人工智能、自然语言处理等领域的常见方法。

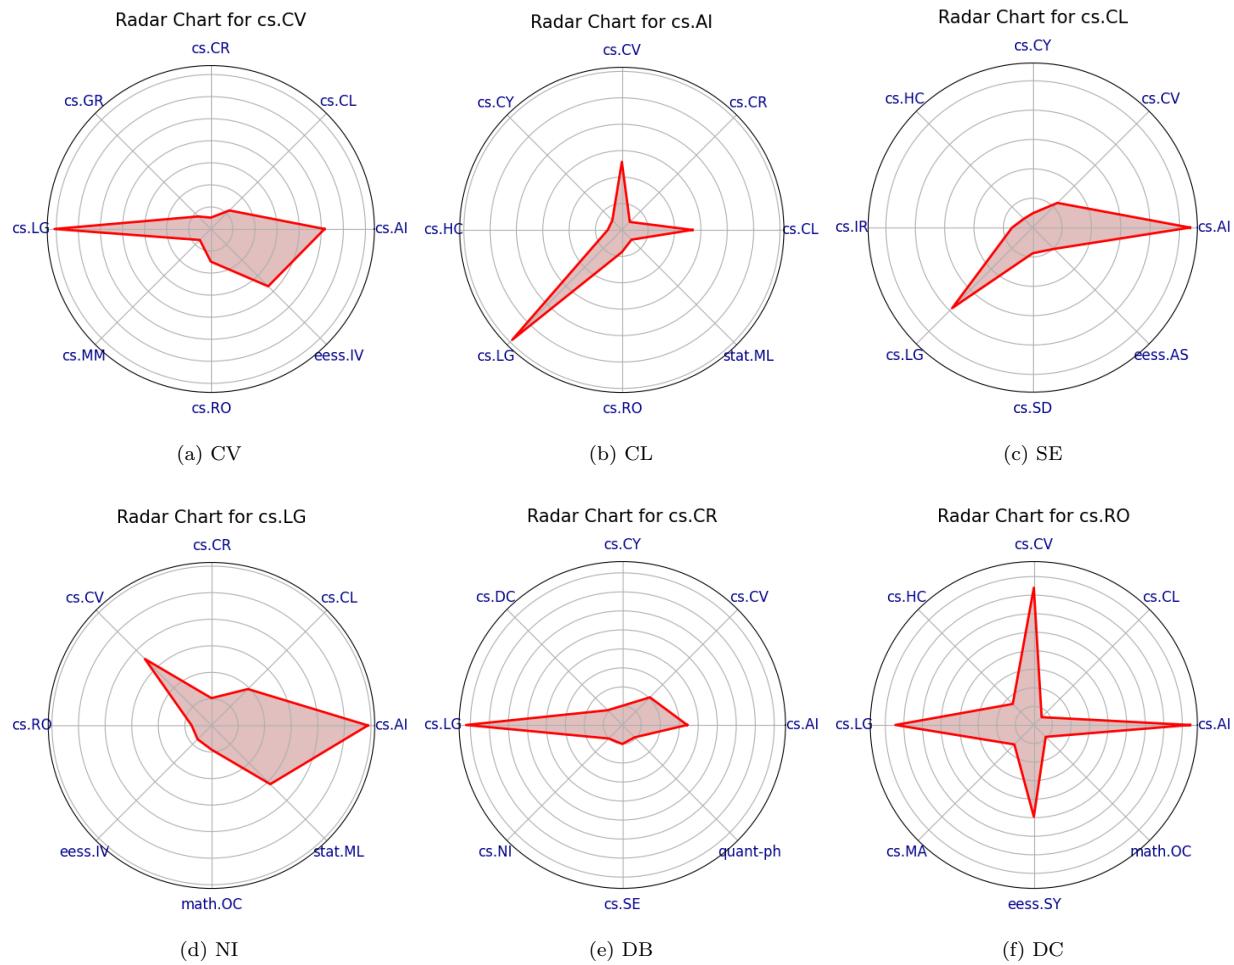


图 11: 相关性分析

5.4.6 最后一次提交的版本和第一次提交版本的时间间隔

本次实验还分析了一篇论文最后一次提交的版本和第一次提交版本的时间间隔。每一篇论文由于修改会多次上传不同的版本（图 12）。根据图 13我们可以分析得到，大多数论文提交的时间间隔在 5 个月以内，时间间隔越长，论文数量越少，这说明更少的研究者会投资超过半年的时间对论文进行修改。



The screenshot shows a detailed view of an arXiv paper page. At the top, it displays the Cornell University logo and the text "Served from the cloud". On the right, there's a search bar and a link to "Access Paper". The main content area shows the title "Attention Is All You Need", author list "Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Łukasz Kaiser, Illia Polosukhin", and a brief abstract. Below the abstract, there's a "Submission history" section highlighted with a red box, showing multiple revisions and their dates. The sidebar on the right contains links for "Access Paper", "References & Citations", and "Bibliographic Tools".

图 12: 论文示例

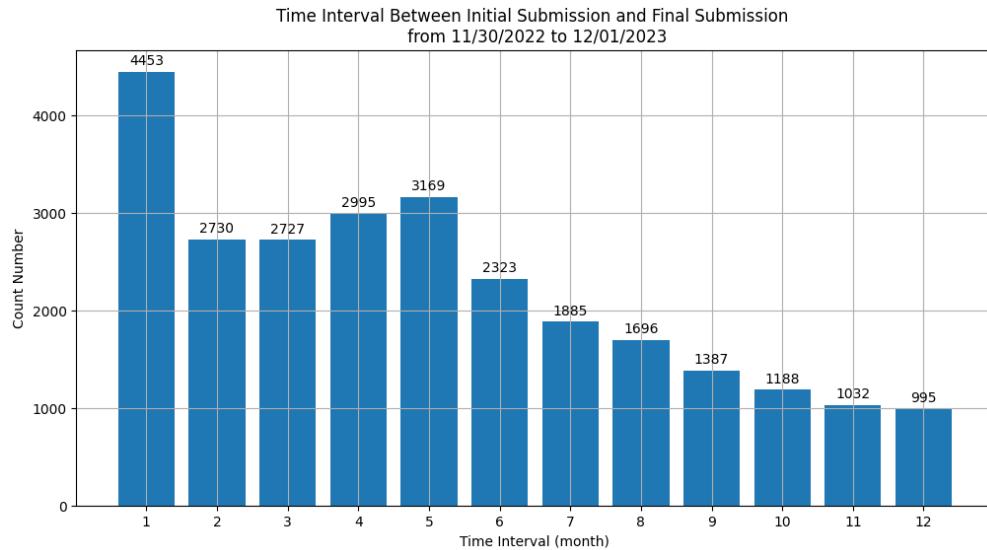


图 13: 最后一次提交的版本和第一次提交版本的时间间隔

5.5 算法设计——针对更细粒度的划分

5.5.1 问题的背景

在 arXiv 论文数据库中，每篇论文都被分为一个或多个领域 (CV,DB,ML...)，但研究者无法根据 arXiv 中的有效信息判断某一篇论文是这一领域的哪一细分方向。举例而言，在 CL(Computation and Language) 领域有许多任务，如实体识别，情感分类，文本生成等，当研究者看到一篇被标注为 CL 领

域的论文时，他无法快速得知这一篇论文是属于实体识别还是其他任务。

观察到 arxiv 论文数据库的这一缺点，我们希望能对一个领域里的论文进行更细粒度的划分。

5.5.2 Kmeans 聚类

由于在原有 arxiv 论文数据集中，并不存在对每一篇论文更细粒度的标注，这使我们无法使用监督学习相关的分类算法。

Kmeans 算法很好的解决了这个问题。Kmeans 算法是一种无监督学习算法。它的基本思想是，通过迭代寻找 K 个样本簇的一种划分方案，使得聚类结果对应的损失函数最小。其中损失函数可以定义为各个样本距离样本中心点的误差平方和：

$$f(c, \mu) = \sum_{i=1}^M |x_i - \mu_{c_i}|^2$$

其中 x_i 代表第 i 个样本， c_i 代表第 i 个样本所属的簇， μ_{c_i} 代表簇对应的中心点， M 是样本总数。

Kmeans 算法能够帮助我们得到某一领域数据集的分类，并通过观察聚类中论文标题，得到这一聚类所属的细分方向。

5.5.3 特征提取

本实验中采用 BERT+PCA 的方法，对论文标题进行特征提取。我们认为论文标题中含有足够的语义信息，帮助我们判断出某论文所属的细分方向。

1. BERT

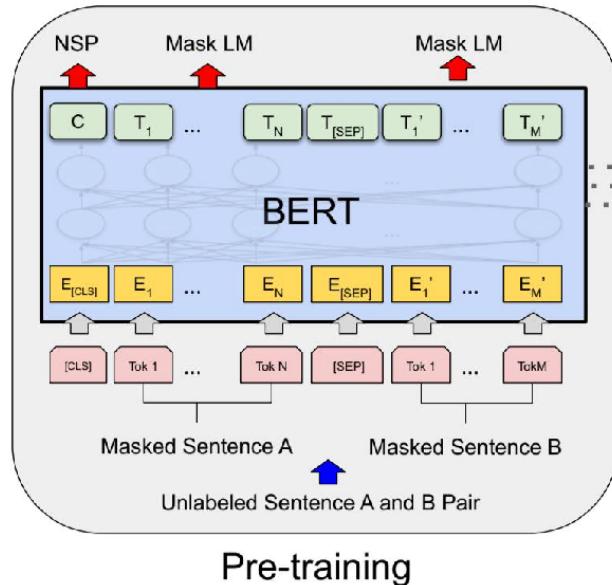


图 14: BERT

- BERT (Bidirectional Encoder Representations from Transformers) 是基于 Transformer 架构的一种创新性预训练语言模型。其核心思想是通过 Transformer 编码器来学习词汇的双向上下文表示，以更全面地捕捉语境和语义。

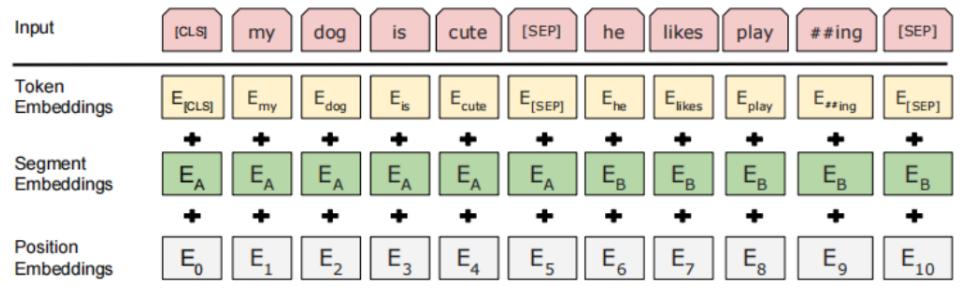


图 15: BERT 的句向量表示

- BERT 通过在句子前加入'[CLS]'token 的方式，通过获取'[CLS]' 的隐藏表示来获得整个句子的句向量。本实验就是使用该方式，使用 BERT 得到每篇文章标题所对应的句向量表示。

2. PCA

- 由于通过 BERT 获取到的句向量维度较大 (728 维)，而 Kmeans 在高维向量上性能较差，采用 PCA 来对 BERT 获取到的句向量进行降维。
- 主成分分析 (Principal Component Analysis, PCA) 是一种常用的降维技术，用于将高维数据映射到低维空间。其目标是找到数据中的主成分，这些主成分是原始特征的线性组合，能够最大程度地保留数据的方差。通过保留主成分，可以减少数据的维度，同时尽量保留原始数据中的信息。

5.5.4 结果分析

对 arXiv 论文数据集中 cs.DB 这一领域进行更细粒度划分，先使用 BERT+PCA 对原数据进行处理，并获取特征向量。

```
title,feature
The Dichotomy of Conjunctive Queries on Probabilistic Structures,"[0.10712351754516612, -1.3161471572191907]"
Why is a new Journal of Informetrics needed?",[-3.3233564644248417, -3.3836279284173467]"
>Data Cube: A Relational Aggregation Operator Generalizing Group-By, Cross-Tab, and Sub-Totals","[-3.2126010174013446, 2.2746677381646516]"
>Data Management: Past, Present, and Future",[-4.161664755437403, -0.4508530340166813]"
>A Critique of ANSI SQL Isolation Levels,"[-1.598995205300393, -2.444493603168891]"
Queues Are Databases,"[-2.2280291151972103, -1.172444825568155]"
>Supporting Finite Element Analysis with a Relational Database Backend, Part I: There is Life beyond Files","[-3.1208392606543285, 0.8890781597232859]"
```

图 16: 数据处理

使用 Sparkml 库中的 KMeans 函数对处理后的数据进行分类，并打印出每个聚类中前十篇论文的标题，这里以 Cluster 2 为例。可以看到这个聚类的论文以数据库性能评估为主，将其分类为 DataBase Performance Evaluation。

Cluster 2 examples:	features
title	
Large-Scale Query and XMatch, Entering the Parallel Zone	[[2.380751927055052, 1.132964876652197]]
Reading policies for joins: An asymptotic analysis	[[2.1532901669856392, 1.2282758386664874]]
VOODB: A Generic Discrete-Event Random Simulation Model to Evaluate the Performances of OODBs	[[2.2239262141631833, 2.6397436556976204]]
OCB: A Generic Benchmark to Evaluate the Performances of Object-Oriented Database Systems	[[3.197498840222998, 1.2610138516717473]]
DWEB: A Data Warehouse Engineering Benchmark	[[2.9889783273950825, 0.9471714714785704235]]
Simrank++: Query rewriting through link analysis of the click graph	[[2.197789243463585, 2.0217220801904983]]
QIS-XML: A metadata specification for Quantum Information Science	[[2.359747592539845, 2.034786669114575]]
DescribeX: A Framework for Exploring and Querying XML Web Collections	[[8.535429704673152, 4.000165194348755]]
Finding links and initiators: a graph reconstruction problem	[[2.131131864593299, 0.9717880499835123]]
SP2Bench: A SPARQL Performance Benchmark	[[5.285844236580435, 0.7588538484598504]]

图 17: Cluster 2

最终的 Kmeans 聚类结果如下图 18, 一共被分为了六个聚类。这六个聚类分别为: 数据库应用、计算系统、数据库性能评估、数据库性能 & 度量、数据库查询和结构的分析、大型对象 (LOB) 存储、聚类和性能评估。

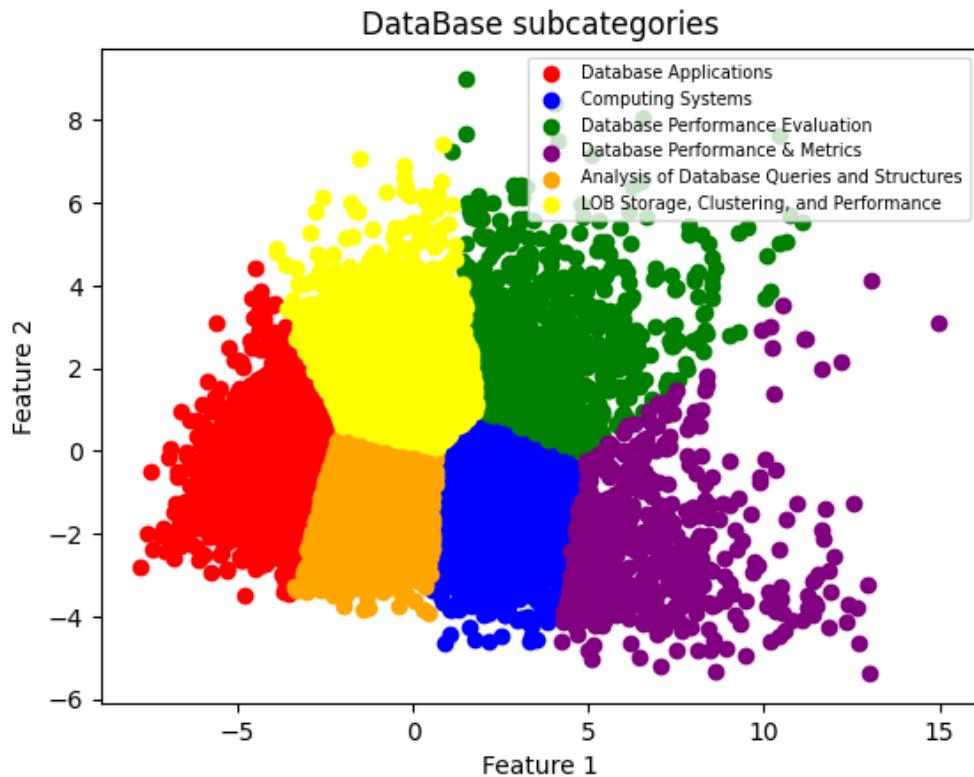


图 18: Kmeans 聚类结果



六、 实验感想与致谢

张鉴殊：在大一上学期我曾选过一门名叫“大数据背景下的市场营销”这门公选，当时对很多大数据分析的理论有所了解，但是一直遗憾于那门课最后我仅仅是写了一篇 5000 字论文作为收尾，并没有实际的运用工具来亲自操刀大数据分析。幸运的是本学期选上了汪润老师的“大数据分析”这门课，并在期末大实验中运用出课上所学的工具以及之前积累的一些理论知识，并且付诸于本次的实验中。

作为小组的组长，我很惊喜的和我的两位队友从一开始就和我处于“同频”状态上，都想真正的来利用大数据工具去做一些我们感兴趣的东西，于是本次的大数据分析实验我们并没有用我们之前打过的数学建模题目来简单的完成任务一（仅仅是解决问题），而是完美的将任务一和任务二融入我们的任务中，恰到好处地发挥出 hadoop 和 spark 处理大数据问题的优势，并且得以分析了离我们科研中十分近的 ArXiv 网站。相信老师可以看出，在本次实验中，我们并没有机械的运用工具去解决单调的问题，而是切实地去分析我们感兴趣的话题，较好地完成了“解决问题”这一初衷。此外，本着为学弟学妹及对 ArXiv 这个平台感兴趣的人们提供大数据分析实战的灵感，我们将所有的代码开源至 https://github.com/sterzhang/BigData_Arxiv_Analysis。

傅彦凯：本次实验我们对 arXiv 上的 CS 论文数据进行了分析。刚开始在定选题的时候，我们小组查阅了很多的资料，其实网上有很多对于天气、碳排放、销售量等数据进行大数据分析的工作，但是这些工作都没有什么新意，不过是在人家的基础上修修改改。而我们小组三人正好也已经在接触科研，一次偶然的机会就提到对科研的数据进行分析，这个想法一拍即合，然后经过充分的讨论，最终确定分析 arXiv 上的论文数据，正好也可以对计算机学科的前沿发展趋势做一定的了解。在确定具体的任务后，我们就开展了分工，最后大家不仅完成了基础的任务，还探讨了 arXiv 网站分类的不足之处，扩展设计了一种更细粒度的划分方法，总体来说，整个过程很有意思，也很有收获。

我要感谢我的两名队友，虽然在刚开始分析这个充满不确定性的选题时，大家都觉得很有挑战，但是小组的每一个成员都能按时、按量地去完成任务，并且还能提出更富有创意的想法。每一次小组会议，大家都能准时参加，给出建设性的意见。在我最初进行数据爬取的时候，对于 arXiv 网站的一些页面跳转机制感到手足无措，但是在两位队友的热心提示下，我豁然开朗，解决了问题。另外也要感谢汪老师，也是我目前在科研上的导师，对我们悉心的教导，希望以后有机会能继续学习您的课程。

彭子恒：本次实验是大数据分析课程的结课实验，需要结合大数据处理技术对大型数据集进行处理和分析，并通过设计算法解决一个具体问题。我们组选择的是“使用 Spark&Hadoop 这两个工具对 Arxiv 数据集进行处理和分析”这一选题。本来在选题设计之初，我们也参考了许多已有的工作，但我们觉得那些工作已经十分丰富以及完善，再复现一遍会觉得十分无趣也没有新意。机缘巧合，我们想到了对 Arxiv 论文数据库分析这个任务。因为我们刚接触到科研，觉得这个任务十分有趣，就着手做起来。



在这次实验中，我主要负责算法设计及实现这部分。和思考选题一样，我起初也没什么思路，网络上已有的算法设计大多都是一些预测模型，与我们选题不相关。并且由于没有太多人做这方面的数据分析工作，使用我们自己爬取的数据很难获取到监督学习算法使用的标签。后来想到自己做科研的时候，很难找到自己想要的细分领域的论文，只能在 Google Scholar 上按照关键字查找，在和队友交流后最终确定了这一思路，并且结合自己会的算法工具，成功的实现了它。

本次实验过程充实且顺利，离不开我队友的努力。在实验中，我们组积极讨论，讨论完就立刻配环境做实验，遇到问题相互交流解决，整个组呈现一种积极向上的良好氛围，也做出了让我们十分满意的结果。同样要感谢汪润老师在大数据分析课上对我们的指导，让我收获满满。



七、附录：配置 hadoop 环境（ubuntu20.04）

- 创建一个 hadoop 用户

```
ster@ubuntu:~$ sudo useradd -m hadoop -s /bin/bash  
[sudo] password for ster:
```

- 为这个用户设置密码，并且设置管理员权限

```
ster@ubuntu:~$ sudo passwd hadoop  
New password:  
Retype new password:  
passwd: password updated successfully
```

```
ster@ubuntu:~$ sudo adduser hadoop sudo  
Adding user `hadoop' to group `sudo' ...  
Adding user hadoop to group sudo  
Done.
```

- 接下来 log out，登录 hadoop 用户



- 先进行软件更新，并且安装 ssh server，这样就能用 ssh 登录主机了

```
hadoop@ubuntu:~$ sudo apt-get update
```

```
Reading package lists... Done  
hadoop@ubuntu:~$ sudo apt-get install openssh-server  
Reading package lists... Done  
Building dependency tree  
Reading state information... Done  
The following additional packages will be installed:  
  ncurses-term openssh-client openssh-sftp-server ssh-import-id  
Suggested packages:  
  keychain libpam-pkcs11 libpam-pkcs11-ssh ssh-askpass molly-guard
```



```
hadoop@ubuntu:~$ ssh localhost
The authenticity of host 'localhost (127.0.0.1)' can't be established.
ECDSA key fingerprint is SHA256:x/P2Dk0pPXvf/F1WA4uhxAUEH95kSwvCgwQpDU9Ns44.
Are you sure you want to continue connecting (yes/no/[fingerprint])? █
```

- 现在开始配置免密登录，先退出 ssh 窗口

```
hadoop@ubuntu:~$ exit
logout
Connection to localhost closed.
```

- 进入 ssh 目录生成密钥，并将密钥加入到授权 keys 中

```
hadoop@ubuntu:~$ cd ~/.ssh/
hadoop@ubuntu:~/ssh$ ssh-keygen -t rsa
Generating public/private rsa key pair.
Enter file in which to save the key (/home/hadoop/.ssh/id_rsa):
Enter passphrase (empty for no passphrase):
Enter same passphrase again:
Your identification has been saved in /home/hadoop/.ssh/id_rsa
Your public key has been saved in /home/hadoop/.ssh/id_rsa.pub
The key fingerprint is:
SHA256:pKXaGQx6KMEzc4ENF8EeiG5diItvggjPbL46knDI9Ic hadoop@ubuntu
The key's randomart image is:
+---[RSA 3072]----+
|..B=+
|o+...
|+=+.+
|o== o =
|o*+ o = S
|*oOE + o
|.B o o
|+
|oo..
+---[SHA256]----+
```

```
cat: ./id_rsa.pub: No such file or directory
hadoop@ubuntu:~/ssh$ cat ./id_rsa.pub >> ./authorized_keys
```

- 现在开始安装 java 环境，并查看 java 版本看是否安装成功

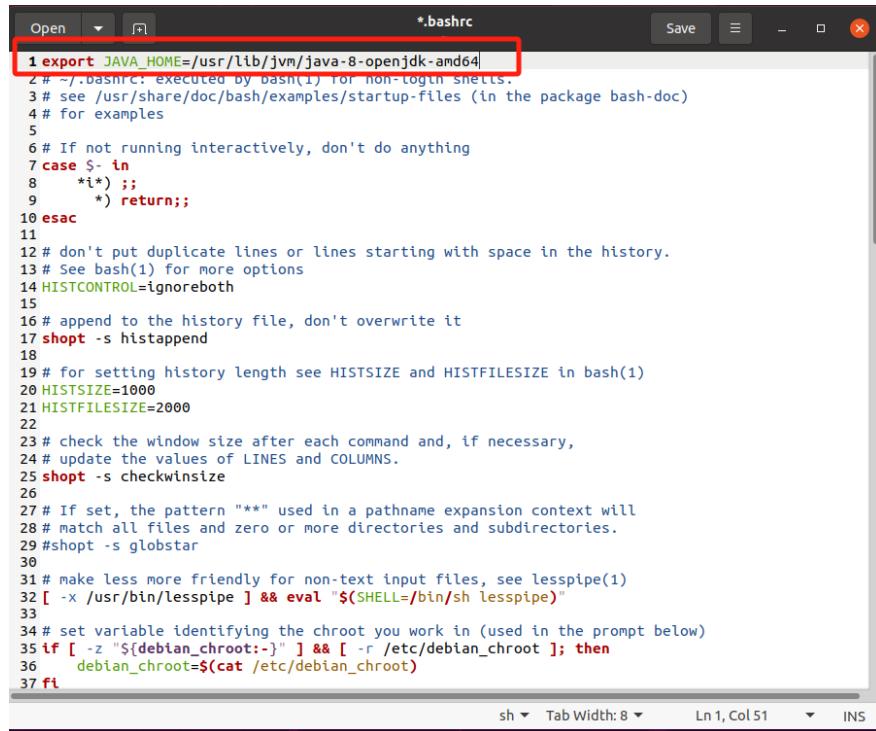
```
Reading package lists...
hadoop@ubuntu:~$ sudo apt-get install openjdk-8-jdk
Reading package lists... Done
Building dependency tree
```

```
hadoop@ubuntu:~$ java -version
openjdk version "1.8.0_392"
OpenJDK Runtime Environment (build 1.8.0_392-8u392-ga-1~20.04-b08)
OpenJDK 64-Bit Server VM (build 25.392-b08, mixed mode)
```

- 现在开始修改相关配置文件（添加第一行），使这个环境变量生效，并进行验证是否成功



```
hadoop@ubuntu:~$ gedit ~/.bashrc
```



```
1 export JAVA_HOME=/usr/lib/jvm/java-8-openjdk-amd64
2 # ~/.bashrc: executed by bash(1) for non-interactive shells.
3 # see /usr/share/doc/bash/examples/startup-files (in the package bash-doc)
4 # for examples
5
6 # If not running interactively, don't do anything
7 case $- in
8     *i*) ;;
9     *) return;;
10 esac
11
12 # don't put duplicate lines or lines starting with space in the history.
13 # See bash(1) for more options
14 HISTCONTROL=ignoreboth
15
16 # append to the history file, don't overwrite it
17 shopt -s histappend
18
19 # for setting history length see HISTSIZE and HISTFILESIZE in bash(1)
20 HISTSIZE=1000
21 HISTFILESIZE=2000
22
23 # check the window size after each command and, if necessary,
24 # update the values of LINES and COLUMNS.
25 shopt -s checkwinsize
26
27 # If set, the pattern "*" used in a pathname expansion context will
28 # match all files and zero or more directories and subdirectories.
29 #shopt -s globstar
30
31 # make less more friendly for non-text input files, see lesspipe(1)
32 [ -x /usr/bin/lesspipe ] && eval "$(SHELL=/bin/sh lesspipe)"
33
34 # set variable identifying the chroot you work in (used in the prompt below)
35 if [ -z "$debian_chroot:" ] && [ -r /etc/debian_chroot ]; then
36     debian_chroot=$(cat /etc/debian_chroot)
37 fi
```

```
hadoop@ubuntu:~$ source ~/.bashrc
hadoop@ubuntu:~$ echo $JAVA_HOME
/usr/lib/jvm/java-8-openjdk-amd64
```

- 现在开始安装 Hadoop，先进入浏览器下载 hadoop



Version	Release date	Source download	Binary download	Release notes
3.3.6	2023 Jun 23	source (checksum signature)	binary (checksum signature) binary-aarch64 (checksum signature)	Announcement
3.2.4	2022 Jul 22	source (checksum signature)	binary (checksum signature)	Announcement
2.10.2	2022 May 31	source (checksum signature)	binary (checksum signature)	Announcement

We suggest the following location for your download:

<https://dlcdn.apache.org/hadoop/common/hadoop-3.2.4/hadoop-3.2.4.tar.gz>

Alternate download locations are suggested below.

It is essential that you verify the integrity of the downloaded file using the PGP signature (`.asc` file) or

- 进行解压，并修改文件夹名称为 hadoop，并修改文件权限

```
hadoop@ubuntu:~$ sudo tar -zxf ~/Downloads/hadoop-3.2.4.tar.gz -C /usr/local

hadoop@ubuntu:~$ cd /usr/local
hadoop@ubuntu:/usr/local$ sudo mv ./hadoop-3.2.4/ ./hadoop

hadoop@ubuntu:/usr/local$ sudo chown -R hadoop ./hadoop
```

- 可以看到目前 hadoop 已经可用了

```
hadoop@ubuntu:/usr/local/hadoop$ ./bin/hadoop version
Hadoop 3.2.4
Source code repository Unknown -r 7e5d9983b388e372fe640f21f048f2f2ae6e9eba
Compiled by ubuntu on 2022-07-12T11:58Z
Compiled with protoc 2.5.0
From source with checksum ee031c16fe785bbb35252c749418712
This command was run using /usr/local/hadoop/share/hadoop/common/hadoop-common-3.2.4.jar
```



- 现在开始利用 hadoop (默认为非分布模式, 无需进行其他配置即可运行), 非分布式即单 java 进程。在这里运行 grep 例子, 将 input 文件夹中所有文件作为输入, 筛选当中符合正则表达式 `dfs-a-z.]^` 的单词, 并统计出现的次数, 将结果输出到 output 文件

```
hadoop@ubuntu:/usr/local/hadoop$ mkdir ./input
hadoop@ubuntu:/usr/local/hadoop$ cp ./etc/hadoop/*.xml ./input
cp: cannot stat './etc/hadoop/*.xml': No such file or directory
hadoop@ubuntu:/usr/local/hadoop$ cp ./etc/hadoop/*.xml ./input
hadoop@ubuntu:/usr/local/hadoop$ ./bin/hadoop jar ./share/hadoop/mapreduce/hadoop-mapreduce-examples-*.jar grep ./input ./output 'dfs[a-z]^'
> ^C
hadoop@ubuntu:/usr/local/hadoop$ ./bin/hadoop jar ./share/hadoop/mapreduce/hadoop-mapreduce-examples-*.jar grep ./input ./output 'dfs[a-z.]^'
```

- 可以看到符合正则表达式的单词共出现 1 次 (若要重新运行, 需要先将这个 output 删除, 因为 hadoop 默认不会覆盖结果文件)

```
hadoop@ubuntu:/usr/local/hadoop$ cat ./output/*
1      dfsadmin
```

- 现在进行 hadoop 伪分布配置, hadoop 可以在单节点上以伪分布式的方式运行, 此时 hadoop 进程以分离的 java 进程来运行, 节点既作为 NameNode, 又作为 DataNode, 同时读取的是 HDFS 的文件

```
hadoop@ubuntu:/usr/local/hadoop$ gedit ./etc/hadoop/core-site.xml
```

- 伪分布式需要修改如下两个配置文件, 修改部分均为 configuration 中的内容

```
core-site.xml
/usr/local/hadoop/etc/hadoop
Save - ×

1 <?xml version="1.0" encoding="UTF-8"?>
2 <?xml-stylesheet type="text/xsl" href="configuration.xsl"?>
3 <!--
4 Licensed under the Apache License, Version 2.0 (the "License");
5 you may not use this file except in compliance with the License.
6 You may obtain a copy of the License at
7
8 http://www.apache.org/licenses/LICENSE-2.0
9
10 Unless required by applicable law or agreed to in writing, software
11 distributed under the License is distributed on an "AS IS" BASIS,
12 WITHOUT WARRANTIES OR CONDITIONS OF ANY KIND, either express or implied.
13 See the License for the specific language governing permissions and
14 limitations under the License. See accompanying LICENSE file.
15 -->
16
17 <!-- Put site-specific property overrides in this file. -->
18
19 <configuration>
20   <property>
21     <name>hadoop.tmp.dir</name>
22     <value>/usr/local/hadoop/tmp</value>
23     <description>Abase for other
24 temporary directories.</description>
25   </property>
26   <property>
27     <name>fs.defaultFS</name>
28     <value>hdfs://localhost:9000</value>
29   </property>
30 </configuration>
```



```
hadoop@ubuntu:/usr/local/hadoop$ gedit ./etc/hadoop/hdfs-site.xml
```

```
hdfs-site.xml
/usr/local/hadoop/etc/hadoop
Save - ×

1 ?xml version="1.0" encoding="UTF-8"?>
2 <?xml-stylesheet type="text/xsl" href="configuration.xsl"?>
3 <!--
4   Licensed under the Apache License, Version 2.0 (the "License");
5   you may not use this file except in compliance with the License.
6   You may obtain a copy of the License at
7
8     http://www.apache.org/licenses/LICENSE-2.0
9
10  Unless required by applicable law or agreed to in writing, software
11  distributed under the License is distributed on an "AS IS" BASIS,
12  WITHOUT WARRANTIES OR CONDITIONS OF ANY KIND, either express or implied.
13  See the License for the specific language governing permissions and
14  limitations under the License. See accompanying LICENSE file.
15 -->
16
17 <!-- Put site-specific property overrides in this file. -->
18
19 <configuration>
20   <property>
21     <name>dfs.replication</name>
22     <value>1</value>
23   </property>
24   <property>
25
26 <name>dfs.namenode.name.dir</name>
27
28 <value>file:/usr/local/hadoop/tmp/dfs/name</value>
29   </property>
30   <property>
31
32 <name>dfs.datanode.data.dir</name>
33
34 <value>file:/usr/local/hadoop/tmp/dfs/data</value>
35   </property>
36 </configuration>
```

- 配置完成后对 namenode 格式化

```
hadoop@ubuntu:/usr/local/hadoop$ ./bin/hdfs namenode -format
```

- 接下来开启 NameNode 和 DataNode 进程，可以通过 jps 来判断是否成功启动（含有 NameNode 和 DataNode 说明成功了）

```
hadoop@ubuntu:/usr/local/hadoop$ ./sbin/start-dfs.sh
Starting namenodes on [localhost]
Starting datanodes
Starting secondary namenodes [ubuntu]
ubuntu: Warning: Permanently added 'ubuntu' (ECDSA) to the list of known hosts.
hadoop@ubuntu:/usr/local/hadoop$ jps
12624 DataNode
12945 Jps
12485 NameNode
12847 SecondaryNameNode
```

- 成功启动后，可通过启动端口 9870 访问 web 页面，这个界面中可以查看 NameNode 和 DataNode 信息，以及在线查看 HDFS 中的文件



The screenshot shows the HDFS NameNode information page at `localhost:9870/dfshealth.html#tab-overview`. The 'Overview' tab is selected. Key statistics include:

Started:	Wed Dec 13 08:03:03 -0800 2023
Version:	3.2.4, r7e5d9983b388e372fe640f21f048f2f2ae6e9eba
Compiled:	Tue Jul 12 04:58:00 -0700 2022 by ubuntu from branch-3.2.4
Cluster ID:	CID-6293d75f39a2-4e1b-a616-2af93078262
Block Pool ID:	BP-1266787088-127.0.1.1-1702483359705

Summary

Security is off.
Safemode is off.
1 files and directories, 0 blocks (0 replicated blocks, 0 erasure coded block groups) = 1 total filesystem object(s).
Heap Memory used 98.44 MB of 244.5 MB Heap Memory. Max Heap Memory is 862.5 MB.
Non Heap Memory used 49.04 MB of 50.52 MB Committed Non Heap Memory. Max Non Heap Memory is <unbounded>.

Configured Capacity:	19.02 GB
Configured Remote Capacity:	0 B
DFS Used:	24 KB (0%)
Non DFS Used:	9.17 GB
DFS Remaining:	8.86 GB (46.59%)
Block Pool Used:	24 KB (0%)
DataNodes usages% (Min/Median/Max/stdDev):	0.00% / 0.00% / 0.00% / 0.00%
Live Nodes	1 (Decommissioned: 0, In Maintenance: 0)

- 在之前的单机模式中，grep 例子读取的是本地数据，伪分布式读取的则是 HDFS 上的数据。这里如果要使用 HDFS，首先需要在 HDFS 中创建用户目录，接着将./etc/hadoop 中的 xml 文件作为 input 文件复制到分布式文件系统中，并通过 ls 查看文件列表

```
hadoop@ubuntu:/usr/local/hadoop$ ./bin/hdfs dfs -mkdir -p /user/hadoop
hadoop@ubuntu:/usr/local/hadoop$ ./bin/hdfs dfs -mkdir input
hadoop@ubuntu:/usr/local/hadoop$ ./bin/hdfs dfs -put ./etc/hadoop/*.xml input
hadoop@ubuntu:/usr/local/hadoop$ ./bin/hdfs dfs -ls input
Found 9 items
-rw-r--r-- 1 hadoop supergroup      9213 2023-12-13 08:07 input/capacity-sche
duler.xml
-rw-r--r-- 1 hadoop supergroup     1032 2023-12-13 08:07 input/core-site.xml
-rw-r--r-- 1 hadoop supergroup    11392 2023-12-13 08:07 input/hadoop-policy
.xml
-rw-r--r-- 1 hadoop supergroup     1077 2023-12-13 08:07 input/hdfs-site.xml
-rw-r--r-- 1 hadoop supergroup      620 2023-12-13 08:07 input/httpfs-site.x
ml
-rw-r--r-- 1 hadoop supergroup    3518 2023-12-13 08:07 input/kms-acls.xml
-rw-r--r-- 1 hadoop supergroup      682 2023-12-13 08:07 input/kms-site.xml
-rw-r--r-- 1 hadoop supergroup      758 2023-12-13 08:07 input/mapred-site.x
ml
-rw-r--r-- 1 hadoop supergroup      690 2023-12-13 08:07 input/yarn-site.xml
```

- 现在查看运行结果，由于刚刚修改了配置文件，所以运行结果不同

```
hadoop@ubuntu:/usr/local/hadoop$ ./bin/hadoop jar ./share/hadoop/mapreduce/hadoo
p-mapreduce-examples-*.jar grep input output 'dfs[a-z.]+'
```

```
hadoop@ubuntu:/usr/local/hadoop$ ./bin/hdfs dfs -cat output/*
1      dfsadmin
1      dfs.replication
1      dfs.namenode.name.dir
1      dfs.datanode.data.dir
```



- 现在将运行结果取回本地（注意 hadoop 在执行的时候，输出目录不能存在）

```
hadoop@ubuntu:/usr/local/hadoop$ ./bin/dfs dfs -get output ./output
hadoop@ubuntu:/usr/local/hadoop$ cat ./output/*
1      dfsadmin
1      dfs.replication
1      dfs.namenode.name.dir
1      dfs.datanode.data.dir
```

- 现在关闭 Hadoop

```
hadoop@ubuntu:/usr/local/hadoop$ ./bin/dfs dfs -rm -r output
Deleted output
hadoop@ubuntu:/usr/local/hadoop$ ./sbin/stop-dfs.sh
Stopping namenodes on [localhost]
Stopping datanodes
Stopping secondary namenodes [ubuntu]
hadoop@ubuntu:/usr/local/hadoop$
```